

รายงานการวิเคราะห์ข้อมูลเบื้องต้น (Exploratory Data Analysis)

Telco Customer Churn Dataset

1. บทนำ

ในยุคดิจิทัลปัจจุบัน ธุรกิจโทรคมนาคมต้องเผชิญกับการแข่งขันที่รุนแรง ลูกค้าสามารถเปลี่ยนผู้ให้บริการได้ง่าย การรักษาลูกค้าเดิมจึงมีความสำคัญมากกว่าการหาลูกค้าใหม่ เนื่องจากต้นทุนในการหาลูกค้าใหม่สูงกว่าการรักษาลูกค้าเดิมถึง 5-25 เท่า

Customer Churn หมายถึง การที่ลูกค้ายกเลิกการใช้บริการและเปลี่ยนไปใช้บริการของคู่แข่ง การทำนายลูกค้าที่มีความเสี่ยงจะยกเลิกบริการล่วงหน้าจะช่วยให้ธุรกิจสามารถวางแผนกลยุทธ์ Retention Campaign เพื่อรักษาลูกค้าไว้ได้ทันเวลาที่

โครงการนี้ใช้เทคนิค Machine Learning โดยเฉพาะอัลกอริทึม Support Vector Machine (SVM) และ Multi-Layer Perceptron (MLP) เพื่อพัฒนาโมเดลทำนายการยกเลิกบริการของลูกค้าโทรคมนาคม โดยใช้ชุดข้อมูล Telco Customer Churn Dataset

2. การอธิบายชุดข้อมูลและระดับความยากในการทำความเข้าใจข้อมูล

2.1 แหล่งที่มาของข้อมูล

แหล่งที่มาของข้อมูล

ชุดข้อมูล Telco Customer Churn Dataset ที่ใช้ในการศึกษานี้ได้มาจาก Kaggle โดยสามารถดาวน์โหลดได้จาก: <https://www.kaggle.com/blastchar/telco-customer-churn>

ไฟล์ข้อมูล: WA_Fn-UseC_-Telco-Customer-Churn.csv

2.2 ขนาดและโครงสร้างของข้อมูล

- จำนวนเรคคอร์ด: 7,043 ลูกค้า
- จำนวนคอลัมน์: 21 คอลัมน์

- ตัวแปรตาม: Churn (Yes/No)

2.3 รายละเอียดของตัวแปร

ตารางที่ 1: รายละเอียดของตัวแปรในชุดข้อมูล Telco Customer Churn

Columns	ประเภทข้อมูล	คำอธิบาย
customer ID	String	รหัสลูกค้า
gender	Categorical	เพศ (Male/Female)
SeniorCitizen	Numerical	สถานะผู้สูงอายุ (1 = ใช่, 0 = ไม่ใช่)
Partner	Categorical	มีคู่ครอง (Yes/No)
Dependents	Categorical	มีผู้อยู่ในความดูแล (Yes/No)
tenure	Numerical	ระยะเวลาการใช้บริการ (เดือน)
PhoneService	Categorical	ใช้บริการโทรศัพท์ (Yes/No)
MultipleLines	Categorical	มีหลายเบอร์ (Yes/No)
InternetService	Categorical	ประเภทบริการอินเทอร์เน็ต (DSL, Fiber optic, No)
OnlineSecurity	Categorical	บริการรักษาความปลอดภัยออนไลน์ (Yes/No)
OnlineBackup	Categorical	บริการสำรองข้อมูลออนไลน์ (Yes/No)
DeviceProtection	Categorical	บริการคุ้มครองอุปกรณ์ (Yes/No)
TechSupport	Categorical	บริการสนับสนุนทางเทคนิค (Yes/No)
StreamingTV	Categorical	บริการสตรีมมิงทีวี (Yes/No)
StreamingMovies	Categorical	บริการสตรีมมิงภาพยนตร์ (Yes/No)
Contract	Categorical	ประเภทสัญญา (Month-to-month, One year, Two year)
PaperlessBilling	Categorical	ใบแจ้งหนี้แบบกระดาษ (Yes/No)
PaymentMethod	Categorical	วิธีการชำระเงิน
MonthlyCharges	Numerical	ค่าบริการรายเดือน
TotalCharges	Numerical	ค่าบริการรวมทั้งหมด
Churn	Categorical	สถานะการยกเลิกบริการ (Yes/No)

2.4 ประเภทของตัวแปร

ตัวแปรเชิงปริมาณ (Numerical Variables) - 3 ตัวแปร:

- tenure (ระยะเวลาการใช้บริการ)
- MonthlyCharges (ค่าบริการรายเดือน)
- TotalCharges (ค่าบริการรวม)

ตัวแปรเชิงคุณภาพ (Categorical Variables) - 17 ตัวแปร:

- ข้อมูลประชากร: gender, SeniorCitizen, Partner, Dependents
- บริการโทรศัพท์: PhoneService, MultipleLines
- บริการอินเทอร์เน็ต: InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies
- สัญญาและการชำระเงิน: Contract, PaperlessBilling, PaymentMethod

ตัวแปรตาม:

- Churn (Yes/No): บอกว่าลูกค้ายกเลิกบริการหรือไม่

2.5. ภาคผนวก (Appendix)

2.5.1 สถิติเชิงพรรณนา

ตารางที่ 2: สถิติของตัวแปรเชิงปริมาณ

Statistic	SeniorCitizen	tenure	MonthlyCharges
Count	7043	7043	7043
Mean	0.16	32.37	64.76
Std	0.37	24.56	30.09
Min	0.0	0.0	18.25
25%	0.0	9.0	35.5

50%	0.0	29	70.35
75%	0.0	55	89.85
Max	1.0	72	118.75

3. วัตถุประสงค์ของการวิเคราะห์

วัตถุประสงค์หลักของการวิเคราะห์นี้คือ เพื่อศึกษาปัจจัยที่ส่งผลต่อการยกเลิกการใช้บริการของลูกค้าโทรคมนาคม (Customer Churn) และพัฒนาโมเดลทำนายเพื่อช่วยธุรกิจลดการสูญเสียลูกค้าและเพิ่มรายได้

การวิเคราะห์จะเน้นไปที่การตอบคำถามสำคัญดังนี้:

- ลูกค้าประเภทไหนที่มีแนวโน้มจะยกเลิกบริการมากที่สุด?
- ปัจจัยใด (เช่น ระยะเวลาการใช้งาน, ประเภทสัญญา, บริการเสริม) ที่มีความสัมพันธ์กับการยกเลิกบริการมากที่สุด?
- เราสามารถสร้างโมเดลที่แม่นยำเพื่อทำนายลูกค้าที่มีความเสี่ยงสูงในการยกเลิกบริการล่วงหน้าได้หรือไม่?

4. การสำรวจข้อมูลเบื้องต้นและการจัดเตรียมข้อมูล (Exploratory Data Analysis & Data Preprocessing)

4.1 การตรวจสอบคุณภาพข้อมูล

ปัญหาที่พบ:

- TotalCharges เป็นประเภท object แทนที่จะเป็น float
- พบค่าว่าง (space " ") ใน TotalCharges จำนวน 11 รายการ

4.2 การกระจายของตัวแปรเป้าหมาย (Churn Distribution)

ตารางที่ 3: การกระจายของ Churn

Churn	จำนวน (Count)	เปอร์เซ็นต์ (%)
Yes	5,174	73.5%
No	1,869	26.5%

การตีความ:

- อัตราการยกเลิกบริการอยู่ที่ 26.5% ซึ่งถือว่าสูง
- ในทุกๆ 4 ลูกค้า จะมี 1 คนที่ยกเลิกบริการ
- ข้อมูลไม่สมดุล (Imbalanced) ต้องใช้ SMOTE ในการแก้ไข

4.3 การกระจายของประเภทสัญญา (Contract Distribution)**ตารางที่ 4: การกระจายของ Contract**

Contract	จำนวน (Count)	เปอร์เซ็นต์ (%)
Month-to-month	3,875	55.0%
Two year	1,695	24.1%
One year	1,473	20.9%

การตีความ:

- ลูกค้ากว่าครึ่ง (55%) ใช้สัญญาแบบรายเดือน
- ลูกค้ากลุ่มนี้สามารถยกเลิกบริการได้ง่าย มีความเสี่ยงสูง
- เพียง 44.9% เท่านั้นที่ผูกมัดสัญญาระยะยาว

4.4 ความสัมพันธ์ระหว่าง Tenure และ Churn**ตารางที่ 5: ค่าเฉลี่ย Tenure แยกตาม Churn**

Churn	Tenure เฉลี่ย (เดือน)
No (ไม่ยกเลิก)	37.6
Yes (ยกเลิก)	18.0

การตีความ:

- ลูกค้าที่ยกเลิกบริการมี tenure เฉลี่ยเพียง 18 เดือน
- ลูกค้าที่ไม่ยกเลิกมี tenure เฉลี่ย 37.6 เดือน (มากกว่า 2 เท่า)

- ช่วง 6-12 เดือนแรกเป็นช่วงวิกฤต ต้องดูแลลูกค้าเป็นพิเศษ

4.6 ขั้นตอนการจัดเตรียมข้อมูล (Data Preprocessing)

4.6.1 การจัดการข้อมูลที่ขาดหายไป (Missing Data Handling)

ผลลัพธ์: แปลงค่าว่าง (space) เป็น 0.0 และเปลี่ยนประเภทข้อมูลเป็น float

4.6.2 การลบตัวแปรที่ไม่จำเป็น

เหตุผล: customerID เป็นเพียงรหัสประจำตัว ไม่มีความหมายในการทำนาย

4.6.3 การแปลงตัวแปรเป้าหมาย (Target Encoding)

ผลลัพธ์:

- Yes → 1 (ยกเลิกบริการ)
- No → 0 (ไม่ยกเลิกบริการ)

4.6.4 การแปลงตัวแปรเชิงคุณภาพ (Label Encoding)

ตัวแปรที่ทำ Label Encoding (15 ตัวแปร):

- gender, Partner, Dependents, PhoneService, MultipleLines
- InternetService, OnlineSecurity, OnlineBackup, DeviceProtection
- TechSupport, StreamingTV, StreamingMovies
- Contract, PaperlessBilling, PaymentMethod

5. ระเบียบวิธีวิจัย (Methodology)

5.1 ประเภทของการเรียนรู้ (Learning Type)

โครงงานนี้ใช้ Supervised Learning (การเรียนรู้แบบมีผู้สอน) เนื่องจาก:

- มีตัวแปรเป้าหมาย (Churn) ที่ระบุชัดเจน

- เป็นปัญหา Binary Classification (2 คลาส: Churn/Not Churn)
- ใช้ข้อมูลในอดีตเพื่อทำนายผลลัพธ์ในอนาคต

5.2 การแบ่งข้อมูล (Data Splitting)

สัดส่วนการแบ่งข้อมูล:

- Training Set: 5,634 รายการ (80%)
- Testing Set: 1,409 รายการ (20%)

5.3 การจัดการข้อมูลไม่สมดุล (Handling Imbalanced Data)

ปัญหา: ข้อมูลมีสัดส่วน No Churn : Churn = 73.5% : 26.5% (ไม่สมดุล)

วิธีแก้ไข: ใช้เทคนิค SMOTE (Synthetic Minority Over-sampling Technique)

ผลลัพธ์:

- ก่อน SMOTE: Class 0 = 4,138 | Class 1 = 1,496
- หลัง SMOTE: Class 0 = 4,138 | Class 1 = 4,138
- รวมทั้งหมด: 8,276 รายการ (เพิ่มขึ้นจาก 5,634)

5.4 อัลกอริทึมที่ใช้ในการวิจัย

5.4.1 Support Vector Machine (SVM)

คำอธิบาย: SVM เป็นอัลกอริทึมที่ทรงพลังในการจำแนกประเภท ทำงานโดยการหาเส้นแบ่ง (hyperplane) ที่เหมาะสมที่สุดเพื่อแยกข้อมูล 2 กลุ่มออกจากกัน โดยพยายามทำให้ระยะห่าง (margin) ระหว่างเส้นแบ่งกับจุดข้อมูลที่ใกล้ที่สุดมีค่ามากที่สุด

จุดเด่น:

- ทำงานได้ดีกับข้อมูลมิติสูง (high-dimensional data)

- มีประสิทธิภาพแม้ข้อมูลมีการทับซ้อนกัน
- ให้ Recall สูงสำหรับการจับลูกค้าที่จะ churn

พารามิเตอร์ที่ใช้:

- **kernel='linear':** เหมาะกับข้อมูลที่แยกได้ด้วยเส้นตรง
- **C=1.0:** ค่ามาตรฐาน ควบคุมการ trade-off ระหว่าง margin กับ misclassification
- **gamma='scale':** ปรับอัตโนมัติตามจำนวนฟีเจอร์

5.4.2 Multi-Layer Perceptron (MLP)

คำอธิบาย: MLP เป็น Neural Network แบบ Feed-forward ที่มี hidden layers สามารถเรียนรู้ความสัมพันธ์ที่ไม่เป็นเชิงเส้น (non-linear relationships) ได้ดีเยี่ยม เหมาะสำหรับการค้นหารูปแบบที่ซับซ้อนในข้อมูล

โครงสร้าง:

- Input Layer: 19 neurons (จำนวนฟีเจอร์)
- Hidden Layer: 100 neurons (1 ชั้น)
- Output Layer: 1 neuron (Binary classification)

จุดเด่น:

- เรียนรู้รูปแบบที่ซับซ้อนได้
- สามารถจับความสัมพันธ์แบบ non-linear
- มีความยืดหยุ่นสูงในการปรับโครงสร้าง

พารามิเตอร์ที่ใช้:

- **hidden_layer_sizes=(100,):** 1 hidden layer มี 100 neurons
- **max_iter=300:** จำนวนรอบการเรียนรู้เพียงพอสำหรับข้อมูลขนาดนี้

6. ผลการทดลองและการวิเคราะห์ (Results and Analysis)

6.1 การทดสอบในสัดส่วน 80:20 (Training: 5,634 | Testing: 1,409)

การกระจายของข้อมูลทดสอบ:

- No Churn: 1,036 รายการ (73.5%)
- Churn: 373 รายการ (26.5%)

6.1.1 Support Vector Machine (SVM)

ประสิทธิภาพโดยรวม:

- Accuracy: 76.15%
- Precision (Churn): 0.54
- Recall (Churn): 0.75
- F1-Score (Churn): 0.62

การตีความ Confusion Matrix:

ผลการทำนาย	จำนวน	ความหมาย
True Negatives (TN)	795	ทำนายถูกว่าไม่ churn → จริงไม่ churn
False Positives (FP)	241	ทำนายว่า churn → แต่จริงไม่ churn
False Negatives (FN)	95	ทำนายว่าไม่ churn → แต่จริง churn
True Positives (TP)	278	ทำนายถูกว่า churn → จริง churn

Classification Report:

Metric	Class 0 (No Churn)	Class 1 (Churn)
Precision	0.89	0.54
Recall	0.77	0.75
F1-Score	0.83	0.62
Support	1,036	373

6.1.2 Multilayer Perceptron (MLP)

ประสิทธิภาพโดยรวม:

- Accuracy: 78.99%
- Precision (Churn): 0.60
- Recall (Churn): 0.60
- F1-Score (Churn): 0.60

การตีความ Confusion Matrix:

ผลการทำนาย	จำนวน	ความหมาย
True Negatives (TN)	890	ทำนายถูกว่าไม่ churn → จริงไม่ churn
False Positives (FP)	146	ทำนายว่า churn → แต่จริงไม่ churn
False Negatives (FN)	150	ทำนายว่าไม่ churn → แต่จริง churn
True Positives (TP)	223	ทำนายถูกว่า churn → จริง churn

Classification Report:

Metric	Class 0 (No Churn)	Class 1 (Churn)
Precision	0.86	0.60
Recall	0.86	0.60
F1-Score	0.86	0.60
Support	1,036	373

6.2 การเปรียบเทียบ SVM และ MLP (สัดส่วน 80:20)

ตารางที่ 5: เปรียบเทียบประสิทธิภาพของ 2 โมเดล

Metric	SVM	MLP	ผู้ชนะ
Accuracy	76.15%	78.99%	MLP
Precision (Churn)	0.54	0.60	MLP
Recall (Churn)	0.75	0.60	SVM

F1-Score (Churn)	0.62	0.60	SVM
True Negatives	795	890	MLP
False Positives	241	146	MLP
False Negatives	95	150	SVM
True Positives	278	223	SVM

การวิเคราะห์เชิงลึก:

MLP ชนะในด้าน:

- Accuracy สูงกว่า 2.84%
- False Positives ต่ำกว่า (ประหยัดต้นทุน)
- True Negatives สูงกว่า (ทำนายลูกค้าปกติได้ดี)

SVM ชนะในด้าน:

- Recall สูงกว่า 15% (จับลูกค้า churn ได้มากกว่า)
- False Negatives ต่ำกว่า 55 ราย (พลาดลูกค้าน้อยกว่า)
- True Positives สูงกว่า 55 ราย

6.3 การวิเคราะห์เชิงเปรียบเทียบ (Comparative Analysis)

ตารางที่ 6: เปรียบเทียบประสิทธิภาพทั้ง 2 สัปดาห์

Model	Train:Test	Accuracy	Precision (Churn)	Recall (Churn)	F1-Score	FP	FN
SVM	80:20	76.15%	0.54	0.75	0.62	241	95
SVM	70:30	75.20%	0.53	0.75	0.62	379	145
MLP	80:20	78.99%	0.60	0.60	0.60	146	150
MLP	70:30	63.66%	0.42	0.91	0.58	716	52

การวิเคราะห์ความเสถียร (Stability Analysis):

SVM - เสถียรสูง:

- Accuracy ลดลงเพียง 0.95% (เกือบไม่เปลี่ยน)
- Recall คงที่ที่ 0.75 ในทั้ง 2 สัปดาห์
- การทำงานสม่ำเสมอ ไม่ว่าจะมียุค training มากหรือน้อย
- เหมาะสำหรับ production

MLP - ไม่เสถียร:

- Accuracy ลดลง 15.33% (ลดลงรุนแรง)
- Recall เพิ่มขึ้นแต่ Precision ลดลง (trade-off ที่ไม่ดี)
- แสดงสัญญาณของ overfitting ในสัดส่วน 80:20
- ไม่เหมาะสำหรับ production

10. สรุป

การศึกษานี้ชี้ให้เห็นว่าเทคนิค Machine Learning สามารถนำมาประยุกต์ใช้เพื่อทำนายการยกเลิกบริการ (Customer Churn) ของลูกค้าโทรคมนาคมได้อย่างมีประสิทธิภาพ โดยเฉพาะอัลกอริทึม Support Vector Machine (SVM) ซึ่งให้ผลลัพธ์ที่มี Recall สูงถึง 75% และแสดงความเสถียรในหลายสัปดาห์ของการแบ่งข้อมูล ทำให้เหมาะสมสำหรับการใช้งานจริง แม้ว่า Multi-Layer Perceptron (MLP) จะให้ค่า Accuracy ที่สูงกว่าเล็กน้อย แต่ความไม่เสถียรและค่า False Negatives ที่มากกว่าทำให้มีข้อจำกัดในการนำไปใช้ในสภาพแวดล้อมจริง